Introduction to Digital Humanities

Projektbericht WS 25/26

Thema: Thematische Analyse von Filmskripten des Horrorgenres

Bryan Herrmann, Matrikelnummer: 3774219

Erklärung: Verwendung von KI-Tools

Ich erkenne die Verwendung von generativen KI-Tools bei der Erstellung dieser Arbeit an, insbesondere chatgpt.com . Ihre Nutzung beschränkte sich strikt auf Rechtschreib- und Grammatikprüfungen sowie auf Vorschläge zur Formulierung und Wortwahl. Zu keinem Zeitpunkt wurden diese Tools zur Generierung eigener Inhalte verwendet. Nach der Nutzung des Tools habe ich die Änderungen sorgfältig überprüft und überarbeitet und übernehme die volle Verantwortung für den Inhalt der Arbeit. Ich habe die folgenden Eingaben verwendet, die je nach Bedarf leicht variiert wurden:

Bitte korrigiere in meinem Text Rechtschreibung und Grammatik

Finde für folgenden Abschnitt eine wissenschaftlichere Formulierung

1. **Introduction:**

Digital Humanities (DH) bezeichnet ein interdisziplinäres Forschungsfeld, in dem digitale Technologien und Methoden systematisch zur Analyse, Visualisierung und Interpretation geisteswissenschaftlicher Fragestellungen eingesetzt werden. Im Gegensatz zu den traditionellen Geisteswissenschaften, die sich vor allem auf die qualitative Interpretation von Texten, historischen Quellen oder kulturellen Artefakten stützen, nutzen DH-Ansätze computergestützte Verfahren, um große Mengen an Daten effizient zu untersuchen und neue Muster zu entdecken. Dabei geht es nicht nur um die technische Anwendung, sondern auch um die kritische Reflexion der Ergebnisse im geisteswissenschaftlichen Kontext. Typische Methoden reichen von Text Mining, Netzwerkanalyse und Topic Modeling bis hin zu digitalen Editionen, 3D-Rekonstruktionen oder Visualisierungen von kulturellen Daten.

In meinem Projekt, der thematischen Analyse von Filmskripten des Horrorgenres, zeigt sich der „Humanities“-Aspekt in der inhaltlichen Interpretation der Ergebnisse. Während die

Datenaufbereitung und das Topic Modeling digitale Methoden sind, zielt die Forschung auf geisteswissenschaftliche Fragestellungen: Welche Themen und Motive prägen Horrorfilme in unterschiedlichen Epochen? Wie spiegeln sich gesellschaftliche, historische oder kulturelle Entwicklungen in der Filmproduktion wider? Welche Unterschiede lassen sich zwischen Subgenres oder Produktionsländern erkennen? Die Analyse geht also über reine Datenverarbeitung hinaus und fordert ein kritisches Verständnis für narrative Strukturen, kulturelle Bedeutungen und historische Kontexte.

Das Projekt lässt sich daher klar einer geisteswissenschaftlichen Disziplin zuordnen, insbesondere der Filmwissenschaft, Kultur- oder Medienwissenschaft. Der innovative Aspekt besteht darin, dass digitale Methoden es ermöglichen, einen sehr großen Korpus von Filmskripten quantitativ zu analysieren und dabei Themenentwicklungen über Jahrzehnte hinweg sichtbar zu machen – etwas, was mit traditionellen Methoden allein nur schwer möglich wäre. Die Kombination aus digitaler Methodik und geisteswissenschaftlicher Fragestellung macht das Projekt zu einem typischen Beispiel für Digital Humanities: Es verbindet datengetriebene Analysen mit interpretativen, kulturwissenschaftlichen Erkenntnissen.

2. Research Agenda:

In meinem Projekt beschäftige ich mich mit der systematischen Analyse von Filmskripten des Horrorgenres. Ziel ist es, zentrale Themen, Motive und narrative Muster innerhalb dieser Filme zu identifizieren und deren zeitliche Entwicklung nachzuvollziehen. Besonders interessiert mich dabei, wie sich die thematische Ausrichtung von Horrorfilmen im Laufe der Jahrzehnte verändert hat, ob bestimmte Themen in spezifischen historischen Phasen dominanter waren und inwiefern diese Veränderungen möglicherweise mit gesellschaftlichen oder historischen Ereignissen zusammenhängen. Ein weiterer Aspekt der Untersuchung ist die Frage, ob sich thematische Muster je nach Subgenre oder Produktionsland unterscheiden, etwa zwischen amerikanischen Slasher-Filmen und europäischen Psychothrillern. Auf diese Weise soll das Projekt nicht nur die inhaltliche Vielfalt des Horrorgenres beleuchten, sondern auch Rückschlüsse auf kulturelle, soziale und mediale Entwicklungen ermöglichen.

Die wissenschaftliche Fragestellung meines Projekts lässt sich folgendermaßen zusammenfassen: Welche zentralen Themen lassen sich in Horrorfilmen identifizieren, wie verändern sie sich über die Zeit, und in welchem Maß spiegeln diese thematischen Verschiebungen gesellschaftliche und historische Kontexte wider? Darüber hinaus wird untersucht, ob bestimmte Themen regional oder subgenrespezifisch ausgeprägt sind. Die Untersuchung verbindet somit eine historische Perspektive mit kulturwissenschaftlicher Analyse und nutzt digitale Methoden, um eine große Anzahl von Texten effizient und systematisch auszuwerten.

Für die Analyse nutze ich ein Korpus von Filmskripten des Horrorgenres, das über den Datensatz „Movie Scripts Corpus“ von Kaggle verfügbar ist. Die Skripte stammen aus unterschiedlichen Zeitperioden, Produktionsländern und Subgenres, wodurch ein vielfältiger Vergleich ermöglicht wird. Vor der Analyse werden die Texte aufbereitet: Stoppwörter werden entfernt, die Tokenisierung, Normalisierung und Lemmatisierung durchgeführt. Anschließend kommt Topic Modeling als Methode zum Einsatz. Diese computergestützte Technik erlaubt es, wiederkehrende Themen und Begriffe in großen Textmengen zu identifizieren und zu gruppieren. Durch die Einbeziehung von Metadaten wie Erscheinungsjahr, Produktionsland und Subgenre lassen sich die thematischen Entwicklungen nicht nur über die Zeit, sondern auch im regionalen und subgenrespezifischen Kontext untersuchen.

Auf diese Weise verbindet das Projekt digitale Methodik mit geisteswissenschaftlicher Fragestellung. Die quantitative Analyse der Skripte liefert eine Grundlage, um narrative Muster und kulturelle Trends sichtbar zu machen, während die inhaltliche Interpretation die Ergebnisse in einen historischen und gesellschaftlichen Kontext einbettet. Somit leistet die Arbeit einen Beitrag sowohl zur Film- und Medienwissenschaft als auch zum Feld der Digital Humanities, indem sie digitale Verfahren für die geisteswissenschaftliche Forschung nutzbar macht.

3. Data Overview:

Für die vorliegende Arbeit wird auf das öffentlich verfügbare Movie Scripts Corpus von Kaggle zurückgegriffen, das eine umfangreiche und kuratierte Sammlung von Filmskripten darstellt. Diese Datenbasis umfasst insgesamt 2.858 Skripte aus verschiedenen Filmgenres und Produktionszeiträumen. Für die Analyse werden daraus gezielt 374 Skripte des Horrorgenres ausgewählt, um eine themenspezifische Untersuchung zu ermöglichen.

Die zeitliche Spannweite der Daten reicht von etwa 1920 bis 2021 und deckt somit nahezu ein Jahrhundert Filmgeschichte ab. Allerdings ist die Verteilung der Daten über die Jahrzehnte hinweg stark unausgeglichen. Der Großteil der verfügbaren Horrorskripte stammt aus den 1980er- bis 2010er-Jahren, während frühere Jahrzehnte (insbesondere vor 1970) mit weniger als 20 Skripten pro Dekade deutlich unterrepräsentiert sind. Diese ungleichmäßige Verteilung stellt eine potenzielle Verzerrung (Bias) dar, insbesondere im Hinblick auf die Analyse zeitlicher Entwicklungen, da Trends in früheren Perioden nur eingeschränkt belastbar identifiziert werden können. Zusätzlich weisen zwei Filme im Datensatz keine Angabe zum Erscheinungsjahr auf und konnten daher nicht in die zeitliche Analyse einbezogen werden.

Die Skripte liegen bereits in vorverarbeiteter Form vor, insbesondere wurden Lemmatisierungsschritte bereits durchgeführt. Zusätzlich enthält das Dataset teilweise

weitergehende Annotationen, beispielsweise durch BERT-basierte Verfahren oder andere algorithmische Ansätze. Diese zusätzlichen Annotationen werden in der vorliegenden Arbeit jedoch nicht genutzt, um methodische Konsistenz zu gewährleisten und den Fokus klar auf das Topic Modeling zu legen. Stattdessen erfolgt eine eigene, standardisierte Textvorverarbeitung (z. B. Stopwortentfernung und Tokenisierung), um die Vergleichbarkeit der Dokumente sicherzustellen.

Ein wesentlicher Vorteil des Datensatzes liegt in den umfangreichen Metadaten, die Informationen wie Erscheinungsjahr, Produktionsland und Subgenre enthalten. Diese ermöglichen es, die identifizierten Themen nicht nur isoliert zu betrachten, sondern auch im Kontext zeitlicher, geografischer und genrespezifischer Unterschiede zu analysieren.

Um die Anzahl der analysierbaren Dokumente zu erhöhen und die Granularität der Themenanalyse zu verbessern, werden die Filmskripte nicht als Ganzes betrachtet, sondern in einzelne Szenen unterteilt. Die Segmentierung erfolgt anhand typischer Szenenmarkierungen wie „INT.“ und „EXT.“. Durch dieses Vorgehen kann das Topic Modeling feinere thematische Strukturen innerhalb der Filme erfassen. Allerdings bringt auch dieser Schritt Einschränkungen mit sich: Insgesamt 31 Skripte enthalten keine klaren Szenenmarkierungen und müssen daher von der Analyse ausgeschlossen werden. Dies reduziert die Datenbasis zusätzlich und kann ebenfalls zu Verzerrungen führen, insbesondere wenn diese Filme systematisch bestimmten Zeiträumen oder Subgenres zuzuordnen sind.

Zusammenfassend bietet das verwendete Dataset eine solide Grundlage für die thematische Analyse von Horrorskripten, insbesondere durch seine Größe und die reichhaltigen Metadaten. Gleichzeitig müssen jedoch mehrere Limitationen berücksichtigt werden, darunter die starke zeitliche Unausgewogenheit, fehlende Jahresangaben einzelner Filme sowie der Ausschluss von Skripten aufgrund fehlender Szenenstruktur. Diese Faktoren können die Aussagekraft der Analyse, insbesondere im Hinblick auf langfristige Entwicklungen, einschränken und sollten bei der Interpretation der Ergebnisse berücksichtigt werden.

Zur Veranschaulichung der Datengrundlage werden in den folgenden Abbildungen sowohl die Anzahl der verwendeten Horrorszenen pro Dekade als auch die Verteilung der Filme mit und ohne erkennbare Szenenmarkierungen dargestellt. Die zugrunde liegenden detaillierten Zahlenwerte sind zusätzlich im zugehörigen GitHub-Repository dokumentiert.

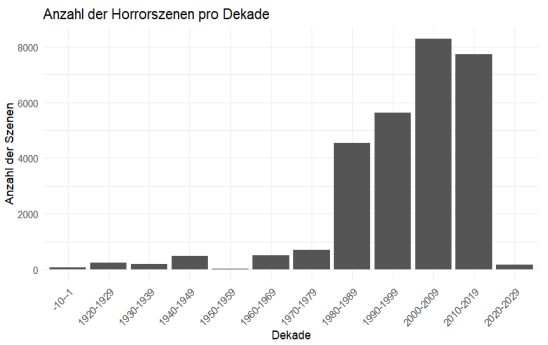

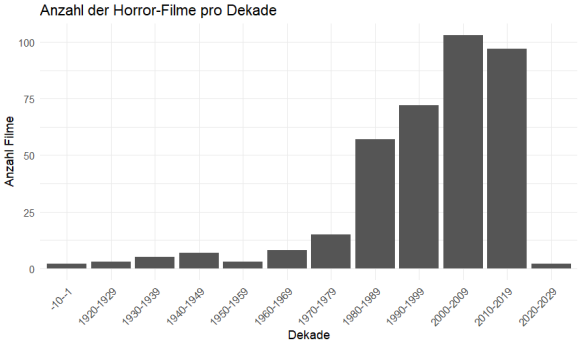

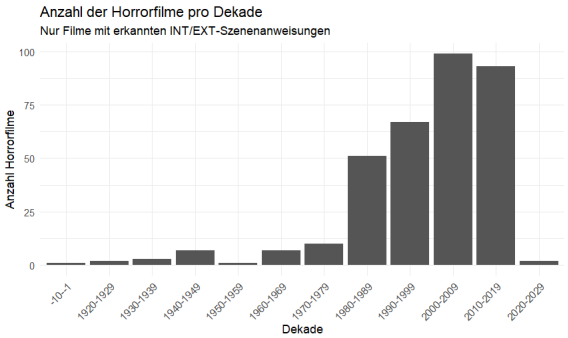

4. Method Overview:

Für die Analyse der Filmskripte meines Projekts kommt Topic Modeling zum Einsatz, eine etablierte Methode des Text Minings, die häufig in den Digital Humanities verwendet wird, um große Textsammlungen systematisch zu untersuchen. Ziel von Topic Modeling ist es, wiederkehrende Themen in Texten zu identifizieren und deren relative Dominanz sichtbar zu machen, ohne dass diese Themen zuvor explizit definiert werden müssen. Die Methode basiert auf statistischen Modellen, typischerweise dem Latent Dirichlet Allocation (LDA)-Modell, das davon ausgeht, dass jedes Dokument eine Mischung aus mehreren Themen ist und jedes Thema durch bestimmte Wortverteilungen charakterisiert wird. Auf theoretischer Ebene verbindet Topic Modeling quantitative Verfahren mit der geisteswissenschaftlichen Analyse, da es die Inhalte der Texte statistisch strukturiert, die Interpretation jedoch qualitative und kontextuelle Expertise erfordert. Die praktische Umsetzung umfasst dabei mehrere Schritte: Zunächst werden die Texte vorverarbeitet, indem Stoppwörter entfernt sowie Tokenisierung, Normalisierung und Lemmatisierung durchgeführt werden. Anschließend wird das LDA-Modell trainiert, um thematische Cluster zu extrahieren, die dann im Hinblick auf zeitliche, regionale oder subgenrespezifische Muster analysiert werden.

Trotz ihrer Stärken weist die Methode einige Grenzen und mögliche Verzerrungen (Bias) auf. So hängt die Qualität der Ergebnisse stark von der Vorverarbeitung der Texte ab: Entfernt man zu viele Wörter, können relevante Themen verloren gehen; lässt man irrelevante Wörter stehen, entstehen unklare oder verzerrte Themen. Auch die Auswahl der Anzahl der Themen ist eine subjektive

Entscheidung, die das Ergebnis erheblich beeinflussen kann. Topic Modeling erfasst zudem Wortverteilungen, keine semantischen Bedeutungen im engeren Sinne; homonyme oder mehrdeutige Begriffe können zu Fehlinterpretationen führen. Außerdem spiegelt das Modell statistische Muster wider, nicht notwendigerweise kulturelle oder narrative Intentionen der Filmemacher. Ein weiterer potenzieller Bias kann aus der Auswahl der Filme resultieren: Der Datensatz deckt nicht alle Horrorfilme ab, und bestimmte Subgenres oder Produktionsländer könnten überrepräsentiert sein.

Die kritische Auseinandersetzung mit diesen Grenzen ist ein zentraler Bestandteil der geisteswissenschaftlichen Interpretation. Die extrahierten Themen müssen im historischen, kulturellen und narrativen Kontext bewertet werden. Nur durch die Verbindung von quantitativer Modellierung und qualitativer Interpretation können verlässliche Aussagen über die Entwicklung von Motiven und Themen im Horrorgenre getroffen werden. Somit verdeutlicht die Methode sowohl ihre Stärken in der systematischen Verarbeitung großer Textmengen als auch ihre Abhängigkeit von theoretischer Reflexion und methodischer Sorgfalt, was typisch für Ansätze der Digital Humanities ist.

5. **Related Work:**

Topic Modeling ist in den Digital Humanities bereits vielfach eingesetzt worden, um große Textkorpora systematisch zu erschließen und daraus thematische Strukturen abzuleiten. Ein Beispiel hierfür ist die Studie von Kleymann et al. (2022), die untersucht, wie der Begriff „Theory“ in der DH-Forschung verwendet und kontextualisiert wird. Um diese Frage zu beantworten, wenden die Autor:innen LDA-Topic-Modeling auf eine große Sammlung von Abstracts aus DH-Journalen an. Die Methode ermöglicht es, wiederkehrende Themencluster zu identifizieren, anhand derer unterschiedliche Bedeutungszusammenhänge von „Theory“ sichtbar werden, die anschließend qualitativ interpretiert werden (Kleymann et al., 2022).

Ein weiteres Beispiel liefern Heibi et al. (2020), die der Frage nachgehen, wie sich Themen innerhalb einer Digital-Humanities-Fachzeitschrift im Zeitverlauf verändern. Hierfür wird Topic Modeling auf die Abstracts der Artikel angewendet, um automatisch Themen zu extrahieren. Anschließend werden diese Topics diachron analysiert, sodass sichtbar wird, welche Forschungsschwerpunkte zu bestimmten Zeitpunkten dominieren. Die Methode wird somit konkret genutzt, um thematische Entwicklungen über die Zeit hinweg quantitativ nachzuvollziehen (Heibi et al., 2020).

Ein drittes Beispiel ist die Studie von Allen et al. (2017), die sich mit einem großen Korpus klassischer chinesischer Texte beschäftigt und der Frage nachgeht, welche thematischen Strukturen

und Bedeutungszusammenhänge sich in diesen historischen Texten erkennen lassen. Mithilfe probabilistischen Topic Modelings werden latente Themen aus über 18.000 Dokumenten extrahiert. Diese Themen dienen als Ausgangspunkt für die inhaltliche Exploration und Interpretation des Korpus und ermöglichen es, semantische Muster sichtbar zu machen, die bei einer rein manuellen Analyse kaum zu erfassen wären (Allen et al., 2017).

6. **Experiment Design:**

In meinem Projekt habe ich Latent Dirichlet Allocation (LDA) Topic Modeling verwendet, um zentrale Themen in Horrorfilmskripten zu identifizieren. Zunächst wurden die Texte vorverarbeitet: Stoppwörter wurden entfernt, die Tokenisierung durchgeführt, Wörter normalisiert und lemmatisiert, um eine konsistente Grundlage für die Modellierung zu schaffen. Anschließend wurde das LDA-Modell auf den vorbereiteten Textkorpus angewendet, um wiederkehrende Wortmuster zu extrahieren und diese zu übergeordneten Themenclustern zusammenzufassen. Die einzelnen Skripte wurden dabei als Dokumente behandelt, und das Modell sollte sowohl dominante Themen pro Film als auch übergreifende Themen über mehrere Filme hinweg erkennen. Zusätzlich wurden Metadaten wie Erscheinungsjahr, Produktionsland und Subgenre berücksichtigt, um thematische Unterschiede in zeitlicher, regionaler oder subgenrespezifischer Perspektive analysieren zu können.

Bei der praktischen Umsetzung bin ich jedoch auf eine wesentliche Herausforderung gestoßen: Die Anzahl der verfügbaren Horrorfilmskripte war für LDA möglicherweise zu gering. LDA und ähnliche probabilistische Topic-Modelle funktionieren besonders zuverlässig, wenn sie auf größere Textmengen angewandt werden, da die statistischen Zusammenhänge zwischen Wörtern stabiler werden. Mit einem kleinen Korpus kann es vorkommen, dass das Modell keine klar trennbaren Themen erkennt, die Ergebnisse stark variieren oder dass einzelne Themen nur sehr wenige Dokumente abdecken. Dies kann zu einer verzerrten Repräsentation führen und die interpretative Aussagekraft einschränken.

Weitere potenzielle Fehlerquellen ergeben sich aus der Textvorverarbeitung. Eine zu starke Reduktion des Textes durch Entfernen von Wörtern kann relevante Begriffe verlieren, während unzureichende Bereinigung zu „Rauschen“ im Modell führen kann. Ebenso kann die subjektive Auswahl der Themenanzahl das Ergebnis beeinflussen: Wählt man zu wenige Themen, verschmelzen unterschiedliche Motive, wählt man zu viele, entstehen viele kleine, schwer interpretierbare Themen. Schließlich spiegelt LDA statistische Wortmuster wider, nicht die

semantische oder narrative Absicht der Filmemacher, sodass die Ergebnisse immer kritisch interpretiert werden müssen.

Insgesamt zeigt die Anwendung von LDA auf meinem Datensatz sowohl die Möglichkeiten digitaler Methoden in den Geisteswissenschaften – wie die systematische Identifikation von wiederkehrenden Themen – als auch deren Grenzen. Die begrenzte Anzahl von Skripten hat die Analyse erschwert, verdeutlicht jedoch gleichzeitig die Notwendigkeit, quantitative Ergebnisse stets durch qualitative Interpretation und Kontextwissen abzusichern. Trotz dieser Einschränkungen liefert das Projekt wertvolle Einblicke in thematische Strukturen des Horrorgenres und deren mögliche zeitliche Entwicklungen.

7. Results and Discussion:

Mein Code, genauere Angaben zur verwendeten Datenmenge sowie Hinweise zur Reproduzierbarkeit der Analyse sind im zugehörigen GitHub-Repository: https://github.com/bryanherrmann/DH_Projektabgabe/tree/main dokumentiert.

Die Anwendung von Topic Modeling auf die Horrordrehbücher liefert insgesamt ein differenziertes Bild, das stark von der gewählten Datenaufbereitung abhängt. Ein Vergleich zwischen dem ersten LDA-Durchlauf auf vollständigen Skripten und der späteren, verfeinerten Analyse mit Szenenaufteilung und zusätzlicher Textbereinigung zeigt deutlich, wie stark die Ergebnisse durch Vorverarbeitungsschritte beeinflusst werden und welche Art von „Themen“ durch das Modell überhaupt erfasst wird.

Im ersten Durchlauf, bei dem die Skripte als Ganzes analysiert wurden, ließen sich insbesondere in den frühen Dekaden sehr klare und gut interpretierbare Topics beobachten. Die resultierenden Wortcluster enthielten häufig Namen ikonischer Figuren oder eindeutig identifizierbare filmische Motive, etwa Kombinationen wie „dracula“, „helsing“, „mina“ oder „jekyll“, „hyde“. Diese Cluster entsprachen weniger abstrakten Themen als vielmehr konkreten Filmen, Figuren oder narrativen Einheiten. Dies ist jedoch kein methodischer Fehler, sondern ein erwartbares Ergebnis: In frühen Dekaden ist die Anzahl der verfügbaren Filme geringer, und einzelne Werke mit starken, wiederkehrenden Figuren prägen die Wortverteilungen besonders deutlich. Horror erscheint hier stärker figurenzentriert und eng an literarische Vorlagen oder ikonische Stoffe gebunden, wodurch die Topics vergleichsweise klar und kohärent wirken.

In späteren Dekaden zeigte der erste Durchlauf hingegen eine deutliche Verschlechterung der Interpretierbarkeit. Die Topics wurden zunehmend von generischen Verben und skriptspezifischen Begriffen dominiert, etwa „look“, „get“, „see“, „come“ oder technischen Markern wie „int“, „ext“ und „cut“. Diese Wörter treten in Drehbüchern sehr häufig auf und überlagern dadurch die

eigentlich interessanten inhaltlichen Strukturen. Das Modell identifizierte in diesem Fall keine semantischen Themen, sondern statistisch häufige Wortmuster, die vor allem aus der Form von Drehbuchtexten selbst resultieren. Daraus ergibt sich bereits ein wichtiges methodisches Zwischenfazit: Ohne zusätzliche Bereinigung ist LDA auf Filmskripten stark anfällig für formale Artefakte und liefert nur eingeschränkt interpretierbare Ergebnisse.

Im zweiten Durchlauf wurde die Analyse deshalb deutlich stärker kontrolliert. Die Skripte wurden in Szenen segmentiert, Charakternamen wurden – soweit möglich – entfernt, und die Stoppwortliste wurde bewusst stark erweitert. Diese Entscheidung war methodisch gewollt: Ziel war es, nicht nur klassische Funktionswörter zu entfernen, sondern auch häufige, aber für die thematische Analyse wenig aussagekräftige Drehbuch- und Bewegungsausdrücke wie „look“, „see“, „come“, „around“, „away“, „open“ oder technische Marker wie „int“, „ext“, „cut“, „shot“. Die große Stoppwortliste wurde also bewusst gewählt, um zu verhindern, dass formale und skriptspezifische Sprachmuster die Topics dominieren. Damit war allerdings zugleich das Risiko verbunden, dass auch potenziell bedeutungstragende Wörter verloren gehen. Die Vorverarbeitung stellt somit einen bewussten methodischen Eingriff dar, der Interpretierbarkeit verbessern, aber nicht alle Probleme des Modells lösen sollte.

Die späteren Ergebnisse zeigen, dass diese Bereinigung einerseits zu präziseren, andererseits aber auch zu ambivalenten Resultaten führt. Mithilfe der beta-Werte und der Topic-Verteilungen pro Dokument lässt sich erkennen, dass das Modell viele Szenen sehr eindeutig einzelnen Topics zuordnet. Zahlreiche Dokumente weisen für ein einzelnes Topic Werte nahe 1 auf, was bedeutet, dass die Szenen aus Sicht des Modells klar trennbar sind. Diese hohe Trennschärfe heißt jedoch nicht automatisch, dass die Topics inhaltlich stark oder geisteswissenschaftlich leicht interpretierbar sind. Vielmehr zeigt sich, dass LDA in vielen Fällen sehr konsistent zwischen unterschiedlichen Wortfeldern unterscheiden kann, diese Wortfelder aber nicht immer als abstrakte Themen im engeren Sinn lesbar sind.

Für die frühen Dekaden bleibt das Bild relativ klar. In den 1920er- bis 1950er-Jahren sind die Topics weiterhin stark von Eigennamen und filmspezifischen Begriffen geprägt. Die beta-Werte zeigen, dass Begriffe wie „raoul“, „erick“, „jekyll“, „hyde“, „denham“, „driscoll“, „macfarlane“, „fettes“, „henry“ oder „carrington“ innerhalb einzelner Topics ein besonders hohes Gewicht besitzen. Das spricht dafür, dass diese Topics tatsächlich von einzelnen Filmen oder Figurenkonstellationen dominiert werden. In diesen Jahrzehnten identifiziert das Modell also vor allem Werk- und Figurencluster statt genreübergreifender Horrormotive. Inhaltlich lässt sich daraus ableiten, dass früher Horror im Korpus stärker über markante Figuren, literarische Vorlagen und spezifische narrative Kerne organisiert ist.

Die 1960er- und 1970er-Jahre wirken als Übergangsphase. Einerseits bleiben Namen wie „mary“, „arbogast“, „neville“, „anna“, „castevet“, „tommy“ oder „bugenhagen“ weiterhin sichtbar und zeigen, dass einzelne Filme die Ergebnisse noch deutlich prägen. Andererseits treten daneben Wörter auf, die eher auf wiederkehrende Motive oder Szenenstrukturen hinweisen, etwa „blood“, „child“, „scream“, „phone“, „bedroom“ oder „office“. Diese Dekaden zeigen somit erste Ansätze einer stärkeren motivischen Verdichtung, ohne dass sich die Topics bereits vollständig von filmspezifischen Begriffen lösen.

Ab den 1980er-Jahren verschiebt sich das Muster erneut. Trotz der erweiterten Bereinigung dominieren hier häufig Wörter wie „around“, „away“, „behind“, „think“, „leave“, „grab“, „call“, „suddenly“, „front“ oder „side“. Die beta-Werte machen deutlich, dass diese Wörter in den jeweiligen Topics tatsächlich stark gewichtet sind und nicht nur zufällig in den Top-Wörtern auftauchen. Die späteren Dekaden werden also weniger durch markante Figuren oder klar erkennbare Horrormotive strukturiert, sondern stärker durch allgemeine Bewegungs-, Interaktions- und Handlungssprache. Dies spricht dafür, dass das Modell in diesen Zeiträumen eher die sprachliche Dynamik von Drehbüchern erfasst als semantisch klar benennbare Themen des Horrors. Das Problem liegt damit nicht primär in einer zu geringen Trennschärfe des Modells, sondern in den strukturellen Eigenschaften des Korpus und in den Grenzen des Bag-of-Words-Ansatzes.

Die 2020er-Jahre zeigen ein gemischtes Bild. Einerseits treten wieder alltagsnahe und szenische Begriffe wie „phone“, „bedroom“, „kitchen“, „road“, „drive“ oder „police“ auf, andererseits bleiben einzelne Eigennamen wie „muldoon“, „wilson“, „lander“ oder „michael“ stark sichtbar. Dies deutet darauf hin, dass in der jüngsten Dekade erneut einzelne Filme oder Figuren einen relativ großen Einfluss auf die Topics haben, zugleich aber auch moderne Alltagsräume und Kommunikationsmittel deutlicher in die Darstellung des Horrors einfließen.

Insgesamt zeigt der Vergleich der verschiedenen Durchläufe und Auswertungsstufen eine klare Entwicklung: Während der erste Durchlauf vor allem film- und figurenspezifische Cluster sowie strukturelle Artefakte hervorbringt, gelingt es im zweiten Durchlauf besser, formale Störfaktoren zu reduzieren und die statistische Trennschärfe der Topics zu erhöhen. Gleichzeitig wird aber auch deutlich, dass selbst eine umfangreiche Vorverarbeitung die grundlegenden Einschränkungen des Bag-of-Words-Ansatzes nicht vollständig aufheben kann. Die Ergebnisse deuten darauf hin, dass frühe Dekaden stärker durch ikonische Figuren und klar abgegrenzte narrative Motive geprägt sind, während spätere Dekaden eher durch generische Handlungssprache, räumliche Orientierung und Interaktionsmuster strukturiert werden. Dies kann vorsichtig als Hinweis auf eine zunehmende Diversifizierung und Formalisierung des Horrorgenres gelesen werden, bleibt jedoch interpretativ begrenzt.

Im Hinblick auf die Forschungsfrage lässt sich deshalb nur ein eingeschränktes Fazit ziehen. Zwar zeigen sich Veränderungen in den Wortmustern über die Zeit, diese beziehen sich jedoch eher auf die sprachliche und inszenatorische Oberfläche der Drehbücher als auf klar identifizierbare, abstrakte Themen oder eindeutige gesellschaftliche Bedeutungsverschiebungen. Die Verbindung zu historischen oder sozialen Entwicklungen kann mit LDA allein daher nur bedingt hergestellt werden. Für eine tiefere inhaltliche Analyse wären ergänzende Methoden erforderlich, etwa semantisch reichere Modelle, manuelle Annotationen oder eine gezielte Untersuchung einzelner Subgenres und Produktionskontexte.

Insgesamt macht die Analyse sowohl die Möglichkeiten als auch die Grenzen von Topic Modeling auf Filmskripten deutlich. Die Methode ist geeignet, wiederkehrende Muster, Figurencluster und formale Strukturen sichtbar zu machen. Die Identifikation abstrakter Themen bleibt jedoch eingeschränkt. Besonders deutlich zeigt sich, dass die Qualität der Ergebnisse unmittelbar von der Vorverarbeitung abhängt. Die bewusst breit angelegte Stoppwortliste war dabei ein zentraler methodischer Schritt, um die Dominanz formaler Drehbuchsprache zu reduzieren und interpretierbarere Ergebnisse zu erzielen, auch wenn dies mit einem gewissen Informationsverlust verbunden war.

8. Conclusion:

Die vorliegende Arbeit zeigt, dass Topic Modeling ein geeignetes Werkzeug ist, um große Korpora von Filmskripten systematisch zu analysieren und wiederkehrende Muster im Horrorgenre sichtbar zu machen. Die Ergebnisse verdeutlichen jedoch zugleich, dass LDA in erster Linie statistische Wortverteilungen erfasst und weniger abstrakte, semantische Themen identifiziert. Während frühe Dekaden stark von ikonischen Figuren und filmspezifischen Begriffen geprägt sind, dominieren in späteren Zeiträumen zunehmend generische sprachliche Muster und strukturelle Elemente von Drehbüchern.

Ein zentrales Ergebnis ist die hohe Abhängigkeit der Resultate von der Textvorverarbeitung. Erst durch Maßnahmen wie die Entfernung von Charakternamen, die Aufteilung in Szenen und die bewusste Verwendung einer umfangreichen Stoppwortliste konnten interpretierbarere Strukturen sichtbar gemacht werden. Die große Auswahl an Stoppwörtern war dabei eine methodische Entscheidung, um häufige, aber thematisch wenig aussagekräftige Drehbuch- und Bewegungswörter zu reduzieren. Gleichzeitig zeigt sich ein Spannungsfeld zwischen Datenbereinigung und Informationsverlust, da durch das Entfernen solcher Begriffe auch potenziell relevante inhaltliche Hinweise verloren gehen können.

Im Hinblick auf die Forschungsfrage lassen sich zwar Veränderungen in den Wortmustern über die Zeit beobachten, diese beziehen sich jedoch eher auf formale und inszenatorische Aspekte des Genres als auf klar identifizierbare inhaltliche Themen oder gesellschaftliche Entwicklungen. Für weitergehende Analysen wären daher ergänzende Methoden erforderlich, die stärker auf semantische Zusammenhänge eingehen und quantitative Verfahren mit qualitativer Interpretation verbinden.

Insgesamt verdeutlicht das Projekt sowohl die Potenziale als auch die Grenzen von Topic Modeling in den Digital Humanities. Während die Methode wertvolle Einblicke in große Textmengen ermöglicht, bleibt die geisteswissenschaftliche Interpretation entscheidend, um die Ergebnisse sinnvoll einzuordnen.

Literatur

Allen, C., Hall, D., & Shen, L. (2017). *Topic modeling the Hàn diǎn ancient classics*. arXiv. https://arxiv.org/abs/1702.00860

Heibi, I., Peroni, S., & Shotton, D. (2020). *MITAO: A tool for enabling scholars in the humanities to use topic modelling*. arXiv. https://arxiv.org/abs/2011.13886

Kleymann, R., et al. (2022). *Conceptual forays: A corpus-based study of "theory" in digital humanities journals*. Digital Humanities Quarterly / Northeastern NULab (Projektbericht).

Burghardt, M. (2025). Digital humanities. In *Reference Module in Social Sciences*. Elsevier.